

**IMPLEMENTASI ALGORITMA K-MEANS DAN AGGLOMERATIVE
CLUSTERING PADA DATA METEOROLOGI DAN LALU LINTAS
JARINGAN**

Disusun untuk memenuhi tugas pada mata kuliah Data Mining.

Dosen Pengampu:

Ir. I Made Dendi Maysanjaya, S.Pd., M.Eng.

NIP. 199005152019031008



Disusun Oleh:

Gede Bhayu Adhipramana (2415091127)

Made Martha Thalia Sukmawan (2415091104)

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN KEJURUAN
UNIVERSITAS PENDIDIKAN GANESHA
2025/2026**

1. Spesifikasi Dataset

Dalam tugas ini, proses klasterisasi dilakukan pada dua *dataset* berbeda yang diambil dari *repository online*.

Dataset 1: Data Iklim Cuaca Kabupaten Bangli

- **Sumber:** NASA POWER Data Access
- **Periode Data:** 1 Januari 2021 hingga 31 Desember 2025.
- **Dimensi Matriks Akhir:** 60 baris (mewakili total bulan) dan 4 kolom fitur.
- **Fitur yang Digunakan:**
 - PRECTOTCORR: Curah Hujan (mm/hari).
 - T2M: Suhu Rata-rata (°C).
 - RH2M: Kelembaban Udara (%).
 - ALLSKY_SFC_SW_DWN: Iradiasi Matahari.

Dataset 2: Trafik Jaringan Perangkat IoT (RT_IOT2022)

- **Sumber:** Repositori Dataset Kaggle (RT-IoT2022).
- **Dimensi Matriks Akhir:** 2000 baris pertama (dilakukan pemotongan/subset untuk mengoptimalkan beban komputasi).
- **Fitur yang Digunakan:** Didominasi oleh variabel numerik kontinu yang merepresentasikan statistik transmisi paket data jaringan, antara lain:
 - flow_duration: Durasi aliran data antar perangkat.
 - fwd_pkts_tot & bwd_pkts_tot: Total paket data yang dikirimkan dan diterima.
 - fwd_pkts_per_sec & bwd_pkts_per_sec: Laju pengiriman dan penerimaan paket per detik.
 - Fitur statistik *header*, ukuran *payload*, serta penghitung *flag* pada protokol TCP.

2. Preprocessing

Sebelum masuk ke tahap pemodelan dengan algoritma klasterisasi, *Dataset* harus melalui tahap pra-pemrosesan (*preprocessing*) agar format mentahnya dapat dibaca dan dikalkulasi secara adil oleh mesin. Fokus pra-pemrosesan pada *Dataset* meliputi:

Dataset 1: Data Iklim Cuaca Kabupaten Bangli

- **Data Reshaping:** Data mentah NASA memiliki format horizontal (kolom bulan memanjang ke kanan). Kami menggunakan fungsi *Melt* dan *Pivot* di library Pandas untuk mengubahnya menjadi format vertikal kronologis, menghasilkan 60 baris data per bulan.
- **Handling Missing Values:** Sensor satelit NASA merekam angka error -999.0 untuk data yang gagal ditarik. Nilai tersebut dideteksi, diubah menjadi nilai kosong (Null), lalu diisi kembali (imputasi) menggunakan nilai Median dari masing-masing fitur.
- **Feature Scaling:** Algoritma berbasis *Euclidean Distance* sangat sensitif terhadap perbedaan skala besaran angka. Oleh karena itu, *StandardScaler* diaplikasikan agar nilai persentase kelembapan (skala puluhan besar) dan curah hujan (skala satuan kecil) memiliki bobot perhitungan yang setara dan adil.

Dataset 2: Trafik Jaringan Perangkat IoT (RT_IOT2022)

- **Pembersihan Data (*Data Cleaning*):** Log rekaman lalu lintas jaringan secara alami rentan terhadap *noise*, kegagalan transmisi, atau pencatatan ganda. Oleh karena itu, kami melakukan pembersihan data dengan menghapus baris data yang terindikasi duplikat (*drop duplicates*) untuk menghindari bobot ganda pada sentroid klaster. Selain itu, kami juga membuang baris yang memiliki nilai kosong/hilang (*missing values/NaN*) agar perhitungan matematis algoritma tidak mengalami *error*.


- **Seleksi Fitur (*Feature Selection*):** Mengingat klusterisasi merupakan bagian dari *unsupervised learning*, kolom target *Attack_type* dihapus dari dataset. Selanjutnya, kolom pengenalan (*identifier*) seperti indeks tanpa nama dan nomor port jaringan (*id.orig_p*, *id.resp_p*), serta fitur kategorikal bertipe string (*proto*, *service*) dibuang karena algoritma K-Means mengandalkan perhitungan jarak spasial yang hanya bisa memproses nilai numerik.
- **Standarisasi Fitur (*Z-Score Normalization*):** Fitur numerik pada trafik jaringan IoT memiliki rentang skala yang sangat timpang—contohnya, fitur durasi aliran (*flow_duration*) dapat bernilai jutaan, sementara laju paket atau penghitung *flag* TCP hanya berkisar antara 0 hingga 1. Algoritma K-Means dan Agglomerative Clustering sangat bergantung pada kalkulasi *Euclidean Distance*. Jika skala data tidak diseragamkan, fitur berukuran besar akan mendominasi perhitungan jarak. Oleh sebab itu, kami menggunakan teknik *StandardScaler* untuk mengubah distribusi seluruh fitur sehingga memiliki rata-rata (*mean*) = 0 dan standar deviasi = 1.

3. Proses Clustering

Proses pengelompokan data pada draf kerja ini diimplementasikan melalui dua pendekatan utama yaitu K-Means Clustering dan Agglomerative Clustering:


Dataset 1: Data Iklim Cuaca Kabupaten Bangli

- **Pendekatan K-Means (Elbow Method & Silhouette Score)** Untuk menentukan jumlah kluster yang optimal, kami melakukan evaluasi nilai *K* dari jangkauan 2 hingga 10 menggunakan *Elbow Method* dan *Silhouette Score*.



Berdasarkan visualisasi grafik di atas, kurva Sum of Squared Errors (SSE) membentuk titik siku (elbow) yang mulai melandai pada angka $K=3$. Di titik yang sama, nilai Silhouette Score juga menunjukkan angka yang stabil. Oleh karena itu, jumlah kluster ditetapkan sebanyak 3 kelompok. Inisialisasi K-Means dilakukan menggunakan parameter `k-means++`.

- **Pendekatan Agglomerative Clustering:** Pemodelan kedua menggunakan metode *Hierarchical Clustering* dengan metrik *Euclidean* dan algoritma penautan *Ward*. Berikut adalah hasil visualisasi pembentukan klasternya:




Dataset 2: Trafik Jaringan Perangkat IoT (RT_IOT2022)

- **K-Means Clustering:**


Algoritma K-Means dijalankan secara berulang (*iterative*) menggunakan penentuan jumlah kluster dari $K = 2$ hingga $K = 10$. Guna mendapatkan nilai K terbaik, diterapkan dua metode evaluasi:

- **Elbow Method:** Mengukur nilai *Within-Cluster Sum of Squares* (WCSS) atau *Inertia*. Untuk menghindari interpretasi subjektif secara visual dalam mencari titik patahan kurva ("siku"), proses pencarian dijalankan secara otomatis menggunakan pustaka `KneeLocator` (`kneed`) dengan parameter kurva konveks dan arah penurunan.
- **Silhouette Score:** Digunakan sebagai validasi sekunder guna mengukur seberapa dekat setiap titik data dengan tetangga di klasternya sendiri dibandingkan dengan kluster lainnya.



- **Agglomerative Clustering:**

Metode klasterisasi hierarki bertipe *bottom-up* ini diterapkan dengan menggunakan metrik kedekatan jarak *Euclidean* dan algoritma *Ward Linkage*. Metode *Ward* dipilih karena bekerja meminimalkan total varians di dalam kluster pada setiap tahapan penggabungan data. Struktur hubungan antar kelompok data kemudian divisualisasikan melalui bagan *Dendrogram* dengan mengambil sampel 100 baris data pertama agar representasi grafik tetap bersih dan mudah dibaca.



4. Analisis Hasil Klaster

Dataset 1: Data Iklim Cuaca Kabupaten Bangli

Berdasarkan perhitungan K-Means dengan parameter $K=3$, data iklim Kabupaten Bangli berhasil dikelompokkan menjadi 3 profil cuaca utama. Berikut adalah tabel rata-rata nilai tiap klaster:

Dari tabel titik pusat (*centroid*) tersebut, kami menginterpretasikan hasil klaster sebagai berikut:

Klaster (Profil)	Curah Hujan (mm/hari)	Suhu Rata-rata (°C)	Kelembapan Udara (%)	Iradiasi Matahari (MJ/m ² /hari)
Klaster 0	9.30	27.32	81.75	18.74
Klaster 1	1.63	26.37	80.07	19.19
Klaster 2	2.34	27.87	75.45	23.21

Klaster 0 (Profil Musim Hujan / Monsun): Mengelompokkan bulan-bulan dengan curah hujan ekstrem (rata-rata 9.30 mm/hari) dan tingkat kelembaban tertinggi (81.75%). Suhu permukaan tetap hangat (27.32 °C) akibat minimnya pelepasan panas karena tutupan awan.

Klaster 1 (Profil Puncak Kemarau / Bediding): Merepresentasikan bulan-bulan dengan tingkat curah hujan paling kering (1.63 mm/hari). Klaster ini secara akurat merekam fenomena meteorologi "Bediding" di dataran tinggi Bali, di mana suhu permukaan anjlok menjadi yang paling dingin di antara semua profil (26.37 °C).

Klaster 2 (Profil Pancaroba Panas): Menunjukkan fase transisi dengan curah hujan menengah-rendah. Minimnya curah hujan dibarengi dengan paparan iradiasi matahari yang mencapai batas maksimal (23.21 \$MJ/m^2/hari\$), sehingga memicu suhu permukaan memanaskan secara ekstrem hingga mencapai nilai rata-rata tertinggi (27.87 °C).

Dataset 2: Trafik Jaringan IoT

Berdasarkan evaluasi *Elbow Method* yang dihitung secara otomatis menggunakan pustaka *KneeLocator* (kurva konveks), nilai *K* optimal ditetapkan pada angka **K=5**. Titik ini juga divalidasi oleh metrik *Silhouette Score* yang menunjukkan kestabilan pemisahan.

Berikut adalah matriks distribusi (*Cross-Tabulation*) dari hasil pengelompokan algoritma K-Means disilangkan dengan label jenis serangan (*Attack_type*) aslinya:

Klaster (K-Means)	Jenis Aktivitas (Attack_type)	Jumlah Data (Baris)
Klaster 0	MQTT_Publish	849
Klaster 1	MQTT_Publish	1.031
Klaster 2	MQTT_Publish	24
Klaster 3	MQTT_Publish	6

Klaster 4	MQTT_Publish	90
------------------	--------------	----

Interpretasi Kritis Hasil Klasterisasi:

Berdasarkan matriks tabulasi silang di atas, terdapat sebuah temuan analitik yang sangat menarik. Seluruh 2.000 baris sampel data yang digunakan ternyata teridentifikasi sebagai satu entitas anomali tunggal, yakni serangan berbasis protokol **MQTT_Publish**. Hal ini terjadi karena pengambilan sampel berurutan (*sequential top rows*) pada dataset yang sudah terurut secara kategorikal.

Meskipun algoritma K-Means tidak diberikan label target (*unsupervised*), algoritma ini secara cerdas mendeteksi varians matematis di dalam serangan MQTT_Publish tersebut dan memecahnya menjadi 5 sub-profil serangan (*sub-clusters*) berdasarkan intensitas transmisi jaringannya:

- **Klaster 1 (Intensitas Utama):** Merupakan kelompok terbesar yang menampung 1.031 kejadian. Ini mengindikasikan bahwa mayoritas serangan *MQTT_Publish* memiliki profil statistik yang sangat identik dan menjadi pola serangan standarnya.
- **Klaster 0 (Intensitas Sekunder):** Menampung 849 kejadian, menunjukkan variasi serangan *MQTT_Publish* tahap kedua yang pola serangannya sedikit berbeda dibandingkan serangan standar di Klaster 1.
- **Klaster 4, 2, dan 3 (Anomali dalam Anomali):** Mengelompokkan serangan dalam jumlah minoritas berturut-turut sebanyak 90, 24, dan 6 kejadian. Klaster ini sangat krusial karena merepresentasikan serangan yang bersifat ekstrem atau *outlier*, seperti durasi koneksi yang sangat lama atau lonjakan lalu lintas yang tidak wajar.

DAFTAR PUSTAKA

Kaggle. (2023). *RT-IoT2022: Real-Time Internet of Things Traffic Dataset*. Diakses dari repositori Kaggle.

NASA. (2026). *Prediction Of Worldwide Energy Resources (POWER)*. Data iklim historis (2021-2025). Diakses dari <https://power.larc.nasa.gov/>